

執行方式：確保資料跟程式碼都在同個路徑，執行

python <code.py> <sol_name.csv>即可

1. (1%) 請比較說明generative model、logistic regression兩者的異同為何？再分別列出本次使用的資料中五個分得正確/不正確的sample，並說明為什麼如此？

Condition	Kaggle	
	Public	Private
Generative model	0.83894	0.83048
Linear regression	0.85393	0.84989

根據跑出來的數據，推測Generative model因為對資料已經有預估的分佈（Gaussian），因此會對一些資料有錯誤的描述跟預期，而logistic regression比較沒有這個問題，因此會有較好的表現。

2. (1%) 請實作兩種feature scaling的方法（feature normalization, feature standardization），並說明哪種方法適合用在本次作業？

Condition	Kaggle	
	Public	Private
Normalization	0.84545	0.83871
Standardization	0.85614	0.85579

以上表格為用hw2_best.py，epoch改為300，分別做Normalization及Standardization跑出來的數據，可看出Standardization表現較好。

我認為本次作業較適合Standardization，不只是從數據上分數較好，也因為Standardization可以讓資料較接近常態分佈，讓outlier影響更小，因此較適合在大部分的資料預處理，包含此次作業。

3. (1%) 請說明你實作的best model及其背後「原理」為何？你覺得這次作業的dataset比較適合哪個model？為什麼？

我做最好的 model 是把以及fmlwgt這項代表調查人的ID拿掉，然後把age, capital_gain, capital_loss, hours_per_week這些參數乘上2~5次方，接在原本的feature的後面（新增額外feature），做epoch為1000的logistic regression。原因為，其他參數皆為1,0，只有這些項會有明顯差異，因此放大這些項，接成新的參數，會讓各筆資料有較大差異，logistic regression的表現會更好。

4. (3%) Refer to math problem

1

令 x_n 屬於的Class為 C_{x_n} 。

$$P(x_1, x_2, \dots, x_N) = \prod_{n=0}^N P(C_{x_n})P(x_n|C_{x_n})$$

$$\begin{aligned} \log P(x_1, x_2, \dots, x_N) &= \sum_{n=0}^N \log P(C_{x_n}) + \sum_{n=0}^N \log P(x_n|C_{x_n}) \\ &= \sum_{n=0}^N N_k \log P(C_k) + \sum_{n=0}^N \log P(x_n|C_{x_n}) \\ &= \sum_{n=0}^N N_k \log \pi_k + \sum_{n=0}^N \log P(x_n|C_{x_n}) \end{aligned}$$

因為限制在 $\sum_{k=0}^N \pi_k = 1$ 的狀況下，要求 $\log P(x_1, x_2, \dots, x_N)$ 的最大值，因此

令 $f = (\log P(x_1, x_2, \dots, x_N))$ ， $g = \sum_{n=0}^N \pi_k$ ，套用Lagrange multiplier。

$$\nabla f = \lambda \nabla g$$

$$\begin{aligned}\frac{\partial}{\partial \pi_i} f &= \frac{\partial}{\partial \pi_i} \left(\sum_{n=0}^N N_k \log \pi_k + \sum_{n=0}^N \log P(x_n | C_{x_n}) \right) \\ &= \frac{\partial}{\partial \pi_i} N_i \log \pi_i + 0 \\ &= \frac{N_i}{\pi_i}\end{aligned}$$

$$\frac{\partial}{\partial \pi_i} g = \frac{\partial}{\partial \pi_i} \sum_{n=0}^N \pi_k = \frac{\partial}{\partial \pi_i} \pi_i = 1$$

$$\nabla f = \lambda \nabla g$$

$$\begin{bmatrix} \frac{\partial}{\partial \pi_1} f \\ \frac{\partial}{\partial \pi_2} f \\ \cdot \\ \cdot \\ \cdot \\ \frac{\partial}{\partial \pi_K} f \end{bmatrix} = \lambda \begin{bmatrix} \frac{\partial}{\partial \pi_1} g \\ \frac{\partial}{\partial \pi_2} g \\ \cdot \\ \cdot \\ \cdot \\ \frac{\partial}{\partial \pi_K} g \end{bmatrix}$$

$$\begin{bmatrix} \frac{N_1}{\pi_1} \\ \frac{N_2}{\pi_2} \\ \cdot \\ \cdot \\ \cdot \\ \frac{N_K}{\pi_K} \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 1 \\ \cdot \\ \cdot \\ \cdot \\ 1 \end{bmatrix}$$

可得 $\pi_i = \frac{N_i}{\lambda}$ ，而

$$\sum_{n=0}^N \pi_k = \sum_{k=0}^N \frac{N_i}{\lambda} = \frac{N}{\lambda} = 1, \lambda = N$$

因此

$$\pi_i = \frac{N_i}{\lambda} = \frac{N_i}{N} \square$$

2

$$\frac{\partial \log(\det \Sigma)}{\partial \sigma_{ij}} = \frac{1}{\det \Sigma} \frac{\partial \det \Sigma}{\partial \sigma_{ij}} = \frac{1}{\det \Sigma} (-1)^{i+j} |A_{ij}| = \frac{\text{adj} \Sigma}{\det \Sigma} e_j e_i^T = e_j \Sigma^{-1} e_i^T \square$$